UNIDAD 2: MINERÍA DE ELEMENTOS FRECUENTES

ALGORITMOS DE PASADAS LIMITADAS

Blanca Vázquez y Gibran Fuentes-Pineda 7 de septiembre de 2021

Para un número de elementos d grande

- Si no se puede tener en memoria principal la base de datos y los contadores, se necesitan múltiples pasadas
- Muestreo
 - · Muestreo aleatorio simple
 - · Algoritmo Savasere, Omiecinski y Navathe
 - · Algoritmo de Toivonen

MUESTREO ALEATORIO SIMPLE (1)

- Se buscan los conjuntos frecuentes a partir de una muestra aleatoria de la base de datos
- Cada entrada de la base de datos se elige con una probabilidad p
 - Si la base de datos es de tamaño n, tendríamos aproximadamente p · n muestras
- Se aplica el algoritmo apriori, PCY, multietapa o multihash a la muestra

MUESTREO ALEATORIO SIMPLE (2)

- Los conjuntos con soporte muy cercano al umbral pueden o no ser frecuentes en la muestra aleatoria
- Se pueden encontrar conjuntos frecuentes en la muestra que no lo son en la base de datos completa (falsos positivos)
 - Se pueden evitar verificando que sean frecuentes en la base de datos completa en una sola pasada
- Es posible que no se encuentran todos los conjuntos frecuentes (falsos negativos)
 - Se pueden reducir si disminuimos el soporte mínimo en la muestra; por ej. 0.9 · minsup.

ALGORITMO DE SAVASERE, OMIECINSKI Y NAVATHE (SON)

- Se divide la base de datos en trozos y se aplica el algoritmo apriori, PCY, multietapa o multihash a cada trozo
 - Se toman como candidatos los conjuntos frecuentes encontrados en uno o más trozos
 - Si un conjunto no es frecuente en ningún trozo, su soporte es menor a minsup en el conjunto de todos los trozos y en general en la base de datos completa
- En una segunda pasada se descartan los candidatos que no sean frecuentes en el conjunto completo de transacciones

ALGORITMO DE SON EN EL MODELO MAPEO-REDUCCIÓN

- Mapeo 1: Toma el subconjunto de transacciones asignadas y encuentra los conjuntos frecuentes con Apriori, PCY, multietapa o multihash
- 2. Reducción 1: Produce los conjuntos frecuentes que aparecen al menos una vez como candidatos
- 3. Mapeo 2: Recibe todos los candidatos y cuenta sus ocurrencias en una porción de la base de datos
- Reducción 2: Toma cada candidato y suma sus ocurrencias en distintas porciones para producir su soporte en la base de datos completa

ALGORITMO DE TOIVONEN

- Se selecciona una muestra de la base de datos para encontrar candidatos usando un soporte mínimo más pequeño (por ej. 0.9 · p · minsup)
- · Agrega la frontera negativa al conjunto de candidatos
 - La frontera negativa son todos los conjuntos que no son frecuentes en la muestra pero cuyos subconjuntos inmediatos¹ sí lo son
- · Se cuentan los candidatos en la base de datos completa
 - Ningún miembro de la frontera negativa es frecuente: los conjuntos frecuentes son los encontrados en la muestra
 - 2. Algunos miembros de la frontera negativa son frecuentes: no es posible dar una respuesta

¹Subconjuntos con un elementos menos